

-Change Point Model 비교 및 설명 보고서-




학과: AI 빅데이터융합경영학과

학번: 20212550

이름: 김태현

본 보고서에서는 1) 특정 단어의 언급량이 시간의 흐름에 따라 어떻게 달라지는가? 2) 특정 단어의 언급량이 급격히 달라진 시점이 언제인가?를 국회본회의 회의록 데이터에서 단어를 추출해 Change point model을 통해 분석해 보려고 한다. [참사, 국가책임, 추모, 재난] 이 4가지의 단어에 대하여 언급량을 확인할 것이다. 이 단어들을 X축은 Year(년도), Y축은 count(언급횟수)로 하여 그래프로 나타낸 결과는 다음과 같다.



1. 비교 모형들에 대한 요약

모델은 크게 두가지 유형으로 나누었고 각각 사전분포 및 모수에 대해 다르게 책정하였다.

첫번째 모델은 Lambda에 대해 사전분포로 지수분포(Exponential)를 사용하였다. 두번째 모델은 Lambda에 대해 사전분포로 감마분포(Gamma)를 사용하였으며, 모수로는 α , β 를 사용하였다. 감마분포를 선택한 이유는 지수분포보다 더 유연하고, 사전 지식을 더 잘 반영할 수 있기 때문에 비교해보기 위해서 선정하였다. 또한, 이때 α 는 5, β 는 0.05로 설정하였는데, 기대값(100)이 데이터 평균(65.85)보다 높게 잡아 모델 변화 이후 값도 잘 포착하게 하기 위함이며, 분산(200)이 커서 모델 변화 전/후 모두 적절히 포용할 수 있기 때문이다. 이렇게 두가지로 나눈 모델들을 각각 One change point, Two change point, Three change point에 적용하여 총 6개의 상황을 비교해보았다. 아래에서는 각 모델을 지수분포, 감마분포, change point에 따라 모델1-6으로 설명하겠다.

- One change point (Exponential(왼쪽) vs Gamma(오른쪽))

	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat		mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat
theta	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN	theta	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN
lambda_1	11.109	0.496	10.174	12.040	0.003	0.002	39183.0	28206.0	1.0	lambda_1_g1	11.189	0.498	10.259	12.132	0.002	0.002	41548.0	29753.0	1.0
lambda_2	150.791	2.279	146.456	155.037	0.011	0.011	39330.0	29653.0	1.0	lambda_2_g1	150.737	2.300	146.390	155.021	0.011	0.012	42844.0	30256.0	1.0

사후신뢰구간(HDI)는 거의 동일한 수준이며, MCMC를 통해 추정된 통계량(평균, 분산)의 불확실성을 나타내는 MCSE또한 거의 유사하다. r_hat은 수렴진단 지표로 이상적으로 1.0에 가까워야하는데 모두 1.0이므로 수렴한다. 하지만 유효 샘플 크기를 나타내는 ESS는 Gamma모델이 더 크므로 샘플 효율성이 좋고 안정성 면에서 근소하게 우수하다.

비교 결론: 모델 1과 2는 구조적으로 거의 동일하며, 모델 2가 샘플링 안정성(ess_bulk) 면에서 아주 근소하게 우수하다.

- Two change point (Exponential(왼쪽) vs Gamma(오른쪽))

	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat		mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat
theta_1_e2	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN	theta_1_g2	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN
theta_2_e2	61.256	4.953	54.000	65.000	2.221	0.833	5.0	5.0	2.18	theta_2_g2	61.394	4.985	54.000	65.000	2.267	0.877	5.0	5.0	2.38
lambda_1_e2	11.105	0.502	10.154	12.028	0.003	0.003	34684.0	26314.0	1.00	lambda_1_g2	11.187	0.492	10.267	12.125	0.002	0.002	42901.0	29709.0	1.00
lambda_2_e2	89.164	6.737	77.123	98.123	2.737	0.875	8.0	40.0	1.43	lambda_2_g2	89.498	6.682	77.054	97.933	2.792	0.971	8.0	40.0	1.45
lambda_3_e2	243.460	43.075	178.273	285.363	18.940	6.467	8.0	39.0	1.47	lambda_3_g2	244.474	43.033	177.882	284.662	19.341	6.998	7.0	42.0	1.48

사후신뢰구간(HDI)는 거의 동일한 수준이며, MCMC를 통해 추정된 통계량(평균, 분산)의 불확실성을 나타내는 MCSE또한 거의 유사하다. r_hat은 theta_2, lambda_2, lambda_3이 1.1을 넘어가므로 전반적으로 수렴에 실패한다. 또한 두 모델의 ESS 수치도 5~8정도로 낮게 측정되어 샘플 효율성

이 낮음을 알 수 있다.

비교 결론: 모델 3, 4는 분산은 비슷하지만 수렴 진단 지표가 좋지 않아 신뢰성 부족하다. 또한 모델 4가 θ_2 의 평균이 약간 더 높지만 큰 차이 없다.

- Three change point (Exponential(왼쪽) vs Gamma(오른쪽))

	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat
theta_1_g3	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN
theta_2_g3	55.500	2.598	54.000	60.000	1.299	0.750	4.0	4.0	2436672.09
theta_3_g3	65.000	0.000	65.000	65.000	0.000	NaN	40000.0	40000.0	NaN
lambda_1_g3	11.187	0.498	10.223	12.097	0.002	0.003	65818.0	30981.0	1.00
lambda_2_g3	81.609	3.278	75.430	87.563	0.851	0.016	15.0	75.0	1.17
lambda_3_g3	109.620	8.537	98.774	127.313	3.902	2.258	7.0	26.0	1.52
lambda_4_g3	275.956	5.536	265.500	286.343	0.022	0.029	60630.0	30586.0	1.00


	mean	sd	hdi_3%	hdi_97%	mcse_mean	mcse_sd	ess_bulk	ess_tail	r_hat
theta_1_e3	45.000	0.000	45.000	45.000	0.000	NaN	40000.0	40000.0	NaN
theta_2_e3	55.500	2.598	54.000	60.000	1.299	0.750	4.0	4.0	2436672.09
theta_3_e3	65.000	0.000	65.000	65.000	0.000	NaN	40000.0	40000.0	NaN
lambda_1_e3	11.108	0.497	10.177	12.040	0.002	0.002	67940.0	33398.0	1.00
lambda_2_e3	81.490	3.297	75.390	87.648	0.861	0.091	15.0	68.0	1.18
lambda_3_e3	109.623	8.567	98.995	127.622	3.913	2.280	7.0	25.0	1.52
lambda_4_e3	276.530	5.540	266.150	286.976	0.022	0.027	60798.0	32736.0	1.00

모델 5,6 또한 사후신뢰구간(HDI)와 MCSE는 거의 유사한데, r_{hat} 에서 θ_2 가 2.4를 넘어가서 매우 심각한 수렴 불량 문제가 있다. 또한 ESS도 낮아 효율성과 신뢰도가 떨어진다.

비교 결론: 모델 5와 6도 구조적으로 거의 같고 추정값도 매우 유사하다. 하지만 θ_2 의 r_{hat} 이 극단적으로 크고 ESS도 낮아 신뢰가 어렵다.

2. 최종 모형에 대한 설명 및 모수추정치

옆의 사진과 같이 모델 비교를 해봤을 때, elpd_{loo} (예측 정확도)로 확인해봤을 때는 Three change point의 Gamma분포를 사용하였을 때가 가장 높은 성능을 보였다. 하지만 모델 5,6은 r_{hat} 의 수치가 너무 높아 신뢰가 불가능하다. 이는 샘플링이 제대로 되지 않아 실제 성능보다 더 좋아 보일 수 있는 것이기 때문이다. 또한 모델 1은 모델2보다 예측 성능 자체는 근소하게 높지만 ESS의 수치가 낮아 샘플링 안정성에서 조금 떨어진다. 그러므로 최종 모델은 모델 2로 선정하였다.



모델 2가 추정한 높은 변화의 시점(θ)은 45였다. 이때 1994년이고 단어의 언급횟수는 59이다. 바로 다음 년도를 확인해보면 언급횟수가 258회로 급작스럽게 변화하는 것을 볼 수 있다. 또한 변화 전후의 평균 단어 사용량(각각 λ_1, λ_2)를 확인해 보면 λ_1 은 11.189, λ_2 는 150.737로 1994년을 기점으로 단어 사용 빈도가 유의미하게 증가한 것을 확인할 수 있다.

3. 해당 시기에 있었던 이벤트와 모형 분석

먼저 빨간색 수직선의 변화점을 살펴보면 1994년 이후 수치가 급격히 올라간 것을 볼 수 있다. 이는 대한민국 최악의 재난 중 하나인 1995년 삼풍백화점 붕괴로 인해 '참사', '재난' 등의 단어 사용량이 증가한 것으로 보인다. 또한 단어 언급 723회의 최고치를 보이는 2014년에는 304명이 희생된 대형 인재인 세월호 참사가 발생해 그래프가 이와 같은 모양을 띄는 것을 알 수 있다.

