

Conditional Variational AutoEncoder

(CVAE) 구현 보고서

MNIST 손글씨 숫자 데이터셋을 활용한 CVAE 모델 설계 및 분석

AI빅데이터융합경영학과

20212550 김태현

1. 서론

Variational AutoEncoder(VAE)는 입력 데이터를 잠재 공간(latent space)으로 압축하고 이를 다시 복원하는 생성 모델이다. 기본 VAE는 조건 없이 임의의 데이터를 생성하는 반면, Conditional VAE(CVAE)는 클래스 레이블과 같은 조건 정보를 모델에 함께 제공하여 원하는 종류의 데이터를 선택적으로 생성할 수 있다. 본 과제에서는 MNIST 손글씨 숫자 데이터셋(0~9)을 대상으로 숫자 클래스를 조건으로 활용하는 CVAE를 구현한다. 인코더/디코더 구조로 MLP(Multi-Layer Perceptron) 기반 모델과 CNN(Convolutional Neural Network) 기반 모델을 각각 설계하고, 학습 결과 및 생성 품질을 비교·분석한다.

VAE와 CVAE의 핵심 차이: VAE의 인코더는 $q(z|x)$, 디코더는 $p(x|z)$ 를 모델링하는 반면, CVAE는 조건 c 를 추가하여 인코더는 $q(z|x,c)$, 디코더는 $p(x|z,c)$ 를 모델링한다. 즉, 모든 네트워크 입력에 조건 벡터를 함께 제공하는 것이 핵심이다.

2. 모델 설계

2.1 공통 구조

두 모델 모두 PyTorch Lightning의 LightningModule을 상속하여 구현하였다. 잠재 공간의 차원은 $n_dim=2$ 로 설정하여 2차원 잠재 벡터(z_0, z_1)를 사용하며, 조건은 숫자 0~9에 대한 원-핫 인코딩 10차원 벡터로 표현된다. 조건 c 는 학습 시 원-핫 벡터로 변환되어 인코더와 디코더 양쪽에 모두 입력된다. 이를 통해 모델은 "어떤 숫자인지"를 알고 인코딩/디코딩하게 된다. 또한 재매개변수화 트릭(reparameterization trick)을 사용하여 역전파가 가능하도록 잠재 벡터를 $z = \text{mean} + \text{std} * \text{epsilon}$ 형태로 샘플링한다.

2.2 MLP 기반 CVAE

MLP 모델은 이미지를 1차원(784)으로 펼쳐 처리한다. 조건 벡터를 이미지 벡터 뒤에 이어붙여 인코더와 디코더에 입력한다.

구성요소	입력 차원	출력 차원	설명
인코더 FC1	$784+10=794$	512	이미지+조건 결합 첫 번째 은닉층
인코더 FC2	512	256	두 번째 은닉층

평균 출력	256	2	잠재 분포의 평균 벡터
로그분산 출력	256	2	잠재 분포의 로그 분산
디코더 FC1	2+10=12	256	잠재벡터+조건 첫 번째 은닉층
디코더 FC2	256	512	두 번째 은닉층
디코더 출력	512	784	Sigmoid 후 28x28 복원

- 표 1. MLP 기반 CVAE 네트워크 구조 -

2.3 CNN 기반 CVAE

CNN 모델은 이미지의 2차원 공간 구조를 유지하면서 처리한다. 조건 벡터를 28x28 크기의 10개 채널로 확장하여 이미지 채널(1채널)과 결합한다. 인코더는 Conv2d로 공간을 점진적으로 압축하고, 디코더는 ConvTranspose2d로 확장한다.

구성요소	입력	출력	설명
인코더 Conv1	(11,28,28)	(32,14,14)	이미지(1ch)+조건(10ch), stride=2
인코더 Conv2	(32,14,14)	(64,7,7)	stride=2로 공간 압축
평균/분산 출력	64x7x7=3136	2	FC 레이어
디코더 FC	2+10=12	64x7x7	특성맵 크기 복원
디코더 ConvT1	(64,7,7)	(32,14,14)	ConvTranspose2d, stride=2
디코더 ConvT2	(32,14,14)	(1,28,28)	Sigmoid로 최종 이미지 출력

- 표 2. CNN 기반 CVAE 네트워크 구조 -

3. 학습

3.1 데이터셋

MNIST 손글씨 숫자 데이터셋을 사용하였다. 훈련 데이터 60,000장과 테스트 데이터 10,000장으로 구성되며, 각 이미지는 28x28 픽셀의 흑백 이미지이다. 전처리는 ToTensor()만 적용하여 픽셀 값을 0~1 범위로 정규화하였다.

3.2 하이퍼파라미터

하이퍼 파라미터	값	설명
배치 크기 (batch_size)	100	한 번에 학습하는 이미지 수
학습률 (lr)	1e-3	Adam 옵티마이저 학습률
에폭 (max_epochs)	20	전체 데이터 반복 횟수
잠재 차원 (n_dim)	2	잠재 공간의 차원 수
조건 차원 (cond_dim)	10	숫자 0~9 원-핫 인코딩 차원
옵티마이저	Adam	lr=1e-3

- 표 3. 학습 하이퍼파라미터 -

3.3 손실 함수 (ELBO)


CVAE의 손실 함수는 복원 손실(Reconstruction Loss)과 KL 발산 손실의 합으로 구성된다. 이는 Evidence Lower Bound(ELBO)를 최대화하는 것과 동일하다.

- 복원 손실(recon_loss) : 원본 이미지와 복원 이미지 사이의 MSE를 배치 크기로 나눈 값이다.
- KL 발산 손실(kl_loss) : 인코더가 출력하는 잠재 분포 $q(z|x,c)$ 가 표준 정규분포 $p(z)$ 에 가까워지도록 유도한다. $KL = -0.5 * \sum(1 + \log_var - \text{mean}^2 - \exp(\log_var))$
- 전체 손실 : $Loss = recon_loss + kl_loss$

4. 결과 분석

4.1 학습 곡선

20 에폭 학습 동안 train_loss, recon_loss, kl_loss를 기록하였다. 학습 초기에 손실이 크게 감소한 이후, recon_loss와 train_loss는 에폭 내에서 톱니 모양의 진동을 보이며 완만하게 감소하는 추세를 보인다. kl_loss는 전체 학습 과정에서 완만하게 증가하는 경향을 보이는데, 이는 잠재 공간이 점진적으로 정규분포에서 멀어지며 복원 품질과 균형을 맞추는 과정으로 해석된다.




4.2 이미지 복원 결과

MLP 기반 CVAE로 복원한 결과, 전체적인 숫자 형태는 잘 재현되었으며 대부분의 숫자를 육안으로 식별할 수 있는 수준이었다. 다만 잠재 차원이 2로 제한되어 있어 일부 이미지에서 세부 획이 다소 흐릿하게 복원되는 경향이 있었다.

CNN 기반 CVAE도 동일하게 복원을 수행하였으며, MLP와 비교하였을 때 육안으로는 유의미한 차이가 관찰되지 않았다. 이는 MNIST 데이터셋이 28x28의 단순한 흑백 이미지로 구성되어 있어, MLP만으로도 충분히 특징을 학습할 수 있기 때문으로 분석된다. 보다 복


잡한 이미지 데이터셋에서는 CNN의 공간 구조 보존 능력이 더 유의미한 차이를 만들 것으로 예상된다.



- MLP 기반 CVAE 복원 결과(위) vs CNN 기반 CVAE 복원 결과(아래) -

4.3 CVAE 생성 결과 (Gradio UI)

학습된 CVAE 디코더를 생성 네트워크로 활용하여 Gradio UI를 통해 이미지를 생성하였다. 클래스(0~9)를 지정하면 해당 숫자의 이미지가 생성되며, z0, z1 슬라이더를 조절하면 같은 숫자 내에서 다양한 스타일의 이미지가 생성된다. 슬라이더 값이 0일 때는 해당 클래스의 가장 평균적인 형태가 생성되며, 값이 커질수록 잠재 공간에서 멀어져 다양한 변형이 나타난다.



4.4 MLP vs CNN 비교

비교 항목	MLP (CVAE)	CNN (CVAE_CNN)
인코더 구조	FC 레이어 (794->512->256)	Conv2d (11ch->32->64)
디코더 구조	FC (12->256->512->784)	ConvTranspose2d (64->32->1ch)
조건 결합 방식	벡터 이어붙이기	채널로 확장 (28x28 채널)
공간 구조 유지	X (1D로 펼침)	O (2D 유지)
복원 품질	전체 형태 복원 가능	세부 획 표현 우수 예상

5. 결론

본 과제에서는 MNIST 데이터셋을 대상으로 MLP와 CNN 기반의 CVAE를 각각 구현하고 학습 및 생성 성능을 분석하였다. CVAE는 조건 정보를 인코더와 디코더 양쪽에 제공하는 비교적 단순한 변경만으로 원하는 클래스의 이미지를 선택적으로 생성할 수 있었다. 잠재 공간의 차원을 2로 제한하였음에도 숫자 클래스별 클러스터가 의미 있게 형성되었으며, z_0 , z_1 슬라이더 조작으로 같은 숫자의 다양한 스타일을 생성할 수 있었다. MLP와 CNN 모델 모두 MNIST 데이터셋에서 안정적으로 학습되었으며, 복원 이미지 품질에서 육안으로 유의미한 차이는 관찰되지 않았다. 이는 MNIST가 단순한 흑백 이미지로 구성되어 있어 MLP만으로도 충분한 표현력을 가지기 때문으로 분석된다. MNIST처럼 단순한 데이터셋에서는 두 모델 모두 충분한 성능을 보였으나, 더 복잡한 이미지 데이터에서는 CNN 구조가 더 유리할 것으로 예상된다. 향후 개선 방향으로는 잠재 공간 차원 증가, Beta-VAE 적용을 통한 disentanglement 향상, 더 깊은 네트워크 구조 적용 등을 고려할 수 있다.